The 34th Annual Conference of the Japanese Society for Artificial Intelligence, 2020

LightGBM を用いた 不動産投資における高精度価格推定モデルの構築

Constructing a highly accurate price prediction model in real estate investment using LightGBM

李 天埼 Tianqi Li　秋山 卓也 Takuya Akiyama　田坂 祐太 Yuta Tasaka

株式会社 DEVEL
DEVEL Co., Ltd.

In this research, we propose a high-accuracy price prediction model for the purpose of constructing a support system for information collection and automatic analysis of profitable properties in the real estate investment market. In the traditional real estate investment process, investors needed to go through the following processes: 1) collect information on the Internet, 2) make price predictions based on their own judgement, 3) order, 4) negotiate and purchase. 1 and 2 in particular are inefficient because they seem simple, but are very time-consuming and must be repeated many times until a suitable property is found. Therefore, we aim to construct an efficient real estate investment support system by automating the information gathering process and substituting the price prediction process with a machine learning model. In this paper, we focus on the price prediction of part (2) and propose a highly accurate price prediction model using LightGBM. Specifically, the accuracy was improved by incorporating the condominium brand name, which is a price determining factor unique to Japan, and the Geo Data, a geographic factor, into the price prediction model.

1. はじめに

不動産投資市場において，投資家はインカムゲインとキャピタルゲインの 2 つの指標を最大化する事を目的としている．インカムゲインとは，不動産購入後に得られる運用益の事を指す．例えば 3000 万円の不動産を購入した後，家賃 25 万円で賃貸運用した場合，年間で 300 万円の運用益が得られる．これは購入額の 3000 万円に対し年間利回り 10%のインカムゲインを意味する．キャピタルゲインとは，保有不動産を売却した時に，購入時の金額を差し引いた売買差益の事を指す．例えば 3000 万円で購入した不動産を 4000 万円で売却できた場合は差額の 1000 万円がキャピタルゲインとなる．これらのインカムゲイン及びキャピタルゲインを最大化するためには，投資家は不動産を購入する前に，購入後に得られるであろう賃料収入及び売却可能価格を事前に正確に予測できなければならない．

従来の不動産投資市場において，投資家はこのような価格予測を過去の取引事例及び経験則のみから目利きを行うのが一般的であった．それだけでなく，従来の不動産投資プロセスでは，投資家は自ら (1) インターネットで情報を収集し，(2) 目利きで価格予測を行い，(3) 買付けを入れ，(4) 交渉及び購入といった煩雑な作業を全て人手で行う必要があった．特にこの (1) 及び (2) の部分は極めてシンプルな単純作業かつ条件に合う物件が見つかるまで何度も繰り返し行う必要があるため，非効率的である．そこで，(1) の情報収集部分をスクレイピング [*1] 等の自動化技術で代用し，また，(2) の目利きによる価格予測の部分を機械学習モデルで代用する事で，効率的な不動産投資のサポートシステムの実現を目指す．

本研究では，特に 2 の価格予測の部分に焦点を当て，決定木アルゴリズムの LightGBM を用いた実務レベルでの高精度な価格推定モデルを提案する．具体的には，日本特有の価格決定要因であるマンションブランド名や，地理要因の Geo Data を考慮し，価格推定モデルに組み入れる事で精度向上を実現する．

連絡先: 李 天埼，株式会社 DEVEL，東京都文京区本郷 4-1-4 ユニゾ本郷四丁目ビル 4F，Tel: 080-3699-1566，Mail: info@devel.co.jp

*1 予め定められたルールに基づいて，一定の周期ごとに自動で Web サイト上から情報を取得し加工する技術

2. 関連研究

関連分野の先行研究として以下のものが挙げられる．

- ヘドニック・アプローチ

  不動産価格を分析する上で，代表的な手法としてヘドニック・アプローチが挙げられる．ヘドニック・アプローチとは，ある商品をその商品の様々な属性の価値に関する集合体 (属性の束) とみなし，回帰分析を利用して各々の属性価値を推定する手法である．不動産市場において，全く同質の不動産が 2 つと存在しないという特殊性を有しているため，こちらの手法が有効とされ，市場分析によく用いられている [清水 08]．

- ニューラルネットワークによる価格推定

  [福井 18] では，レインズ (Real Estate Information Network System) の中古マンションの成約データ約 4 万件を対象に，ニューラルネットワークを用いて不動産価格査定を分類問題として解いている．

- 決定木アルゴリズムによる価格推定

  [大和 17] では，不動産情報サイト SUUMO における賃貸掲載データ約 300 万件を対象に，家賃の推定を行う際に変数の非線形性を表現できる手法として，決定木アルゴリズムをベースとしたランダムフォレストを利用している．

- 画像情報を用いた価格推定

  [服部 19] では，LIFULL HOME'S データセットのうち約 9 万件を対象に，物件の間取り図をヘドニック・アプローチの属性として見なし，賃料予測の線形回帰モデルに組み入れる事で予測精度の向上を実現している．

- 海外の研究事例

  海外では不動産取引に関する分析データも多く，商用レベルで実用化されている事例も多い．米国最大の不動産情報サイトを運営する Zillow 社では，米国全土の 1 億件を超える不動産物件に対して参考価格を算出し，地図上などで確認できるようにした Zestimate*2 という物件価格査定アルゴリズムを開発している．

3. 提案手法

本研究では，実務レベルでの高精度価格推定モデルを実現する手法として，決定木アルゴリズムの一種である LightGBM [Ke 17] を採用する．

3.1 LightGBM

LightGBM とは，決定木アルゴリズムに基づいた勾配ブースティングのフレームワークである．近年では，世界的な競技プログラミングサイトの Kaggle*3 で，金メダル獲得者達が最もよく使うアルゴリズムとして知られている．アルゴリズムの特徴として，勾配ブースティングの過程において「Leaf-Wise」に決定木を成長させる事で，他の「Level-Wise」の決定木アルゴリズムよりも短時間かつ高精度で学習できる事が挙げられる．また，LightGBM は訓練データの特徴量を階級に分けてヒストグラム化しているため，決定木の厳密な分岐点を探す必要がなく，大規模なデータセットに対しても計算コストを抑えられることが利点である．不動産投資の実務において，十分に大規模な学習データセットを用意できる前提であれば，この LightGBM は非常に適した手法だと言える．

3.2 他の手法と比較した LightGBM の利点

2 節で挙げたニューラルネットワークを用いた手法 [福井 18] では，不動産データにおける非数値の属性がボトルネックとなる．実務における不動産データの属性の多くは非数値データ (所在地，駅名，建物名，管理会社名，方角等) であり，それらをニューラルネットワークで扱う場合，前処理として数値データへの正規化，もしくは one-hot ベクトルへ変換する必要がある．ニューラルネットワークの性質上，これらの前処理を多く挟むほどに学習難易度が上がり，結果としてモデルの精度の低下につながる．また，実務における多くの不動産情報システムでは，多数の任意入力項目が存在し，それらが未入力のまま情報公開される事が多い．そういった未入力項目をニューラルネットワークでは直接扱えないので，精度に影響しない範囲で数値データへ変換する仕組みが必要となる．一方 LightGBM では，非数値データはカテゴリカル変数として扱え，未入力データもそのまま None 値として学習できるので，シンプルな実装で高精度なモデルを学習する事ができる．実際に本研究を行うのに際して，[福井 18] で提案されたニューラルネットワークモデルを再現実装し，LightGBM と比較実験を行った結果，精度面で LightGBM が大きく上回る結果となった．

[大和 17] で提案されたランダムフォレストによる価格推定モデルでは，決定木アルゴリズムという点で有用である．しかし LightGBM と比較した場合，データ量が潤沢に有り，かつ十分にパラメータチューニングされている前提であれば，ランダムフォレストより LightGBM のほうがパフォーマンスが高い事がよく知られている [Zhao 19]．

[服部 19] で提案されるような，画像データを学習モデルに組み込む事で価格推定精度の向上が期待できる．しかしながら，実務レベルにおいては，新規の不動産情報が最初に不動産情報サイトに掲載される時点では，写真未撮影や現地未調査となっているケースも多く見られる．後日にスタッフが現地調査し，追加情報として画像を掲載する場合や，好条件の物件であれば，画像未掲載のまま投資家が買付けを入れて成約に至るケースも有り得る．すなわち即時性が重要となる不動産投資の実務において，投資家は画像情報がない必要最小限な情報でも即時に価格の予測ができなければならない．本研究では，不動産投資の実務におけるサポートシステムの構築を目的としているため，ここでは画像データを用いない事とする．

*2 https://www.zillow.com/zestimate/
*3 https://www.kaggle.com/

表 1: データの概要

属性名	データ例	タイプ	役割
成約価格	4000 万円	数値	目的変数
マンション名	シティタワー芝	カテゴリ	説明変数
所在地	東京都港区港 1 丁目	カテゴリ	説明変数
所在階	10 階	数値	説明変数
平米数	50 平米	数値	説明変数
間取り	2LDK	カテゴリ	説明変数
沿線	JR 山手線	カテゴリ	説明変数
最寄駅	新橋駅	カテゴリ	説明変数
駅徒歩	10 分	数値	説明変数
築年月	2000 年 1 月	日付	説明変数
現況	空室	カテゴリ	説明変数
権利関係	所有権	カテゴリ	説明変数
情報掲載日	2018 年 3 月	日付	説明変数
駐車場	有り	カテゴリ	説明変数

4. 使用するデータ

第 1 節でも述べたように，不動産投資の実務では「売買価格の予測」と「賃料の予測」の 2 つのタスクが必要となる．これらは別々の価格推定モデルを構築する必要があるが，それぞれの違いとしては，目的変数が売価か賃料か異なる点で，それ以外の推定モデルへの入力データはほとんど同じである．ゆえに本論では問題設定をシンプルにするために，売価データのみを用いて価格推定モデルの実験を行う．

また，売価と賃料のどちらの取引データにおいても，「募集価格」と，「成約価格」の 2 種類の価格が存在する．募集価格とは，不動産情報サイトに掲載された時点での売り手が希望する言い値の価格で，成約価格とは，売り手が複数の買い手との交渉の末に実際に取引成立した時に価格である．不動産投資において，投資家が最も知りたい情報は，実際に売れるであろう成約価格の予測なので，ここでは，成約データのみを対象とし実験を行う．

株式会社 DEVEL では，著者らが過去 10 年間以上に渡り，独自に日本中における不動産取引のオープンデータを収集してきた．現在では，募集価格，成約価格の情報を含め約 1 億件以上の大規模な不動産取引事例のデータベースを保有している．今回の実験では，そのうち 2016 年〜2019 年の東京 23 区における区分マンション売買の成約価格データ 63093 件を利用する．

今回使用する成約価格データには，各取引事例のレコードごとに，約 108 項目の属性情報が記録されている (任意入力項目も含む)．そのうち代表的な 15 項目を表 1 に示す．

これら 108 項目の属性情報うち，成約価格を目的変数とし，残りの 107 項目を説明変数として LightGBM モデルへ入力する．その際に，所在地や最寄駅などはカテゴリカル変数として，また，築年月や情報掲載日などの日付情報は「1900 年 1

表 2: LightGBM のハイパーパラメータ

パラメータ名	値
learning_rate	0.01
max_depth	8
num_leaves	16
min_data_in_leaf	5
objective	fair

表 3: 実験結果

手法	MAPE
Neural Networks	10.832
LightGBM	9.603
LightGBM + log	8.598
LightGBM + log + Geo Data	8.412
LightGBM + log + Geo Data + Brand	8.349

月 1 日からの経過時間」といったような連続値に変換した上でモデルへ入力する．

5. 実験

今回の実験では，Mean Average Percentage Error (MAPE) を用いて不動産価格推定結果の評価を行った．これ以外の評価指標として Root Mean Squared Error (RMSE) もよく用いられるが，不動産投資の実務においては，RMSE よりも MAPE のほうが，より直感的に投資家が求める結果が得られる．例として，1 億円の価値の不動産に対しての 500 万円の予測誤差と，1000 万円の価値の不動産に対する 500 万円の予測誤差では，投資家にとって後者のほうが深刻な予測誤差であるにも関わらず，RMSE では同程度のペナルティとして評価される．MAPE を用いる事でこの問題は解消される．

また，今回の実験では全データ 63093 件のうち，2016 年〜2018 年の 48023 件を学習データとし，2019 年の 15070 件を評価データに用いて実験を行った．実験では 5-fold cross validation で学習を行い，テスト時には 5 モデルの平均値を最終的な推定結果としている．更に，学習がオーバーフィットしないために early-termination を行い，最適なイテレーション探索を行った．

今回の実験で用いた LightGBM のハイパーパラメータを表 2 に示す．ここでは目的関数に fair を導入している．fair 関数とは，通常の MSE 関数の原点付近の微分不可能な点を滑らかにしたものである．原点付近で勾配が消失しなくなるため，精度向上に寄与する効果が期待できる．

5.1 log 変換による MAPE 最適化

今回の実験では，評価指標として MAPE を採用しているため，通常の MSE もしくは fair 関数では直接最適化する事ができない．そこで，精度向上の工夫として，学習時に目的変数の成約価格を一度 log 変換にかけた対数値としてモデルの最適化を行った．評価時には，その逆変換でモデルの出力結果を指数関数にかけた後に MAPE による精度評価を行った．

5.2 Geo Data

Kaggle 等のデータ分析コンペティションでは，feature interaction のテクニックを用いて，既知の属性情報を組み合わせて高次の特徴量を作成する事で予測精度を大きく向上させられる事がよく知られている．今回の不動産価格推定モデルでも，より高精度化させるための工夫として，Geo Data 及びマンションブランドといった新たな特徴量を追加で作成した．

Geo Data とは地図上における緯度経度の座標系の情報で，Google が提供している Geocoding API[*4] を利用する事で，各マンション名から地図上における正確な緯度経度の座標値を取得できる．既知の住所の情報を単なるカテゴリカル変数としてモデルに学習させるよりも，緯度・経度の数値情報を与える事で，モデル内で暗黙的に連続した空間上にマッピングされる事が期待できる．その結果，未知の物件でも，モデルは暗黙的に空間上における周囲物件の相場を考慮し，より正確に価格推定できると考えられる．実験結果でも，上記の Geocoding API から得られた緯度・経度の情報，及び最寄り駅の緯度・経度との距離を新たな特徴量としてモデルに組み込む事で，僅かな精度向上効果が観測できた．

5.3 マンションブランド

更に精度向上の工夫としてマンションブランドの特徴量も新たに作成した．マンションブランドとは，マンション名に含まれる特定のブランド名の事で，代表的なものとしては野村不動産のプラウド，東急不動産のブランズ，住友不動産のシティタワー，東京建物のブリリアなどが挙げられる．マンションブランドがある場合はそうでない場合と比べて値上がる傾向が強く，また分譲会社ごとの値上げ戦略によっても価格上昇のペースが異なる．これらの関係性をモデルに学習させやすくするために，明示的な特徴量として作成し，追加でモデルへ入力した．具体的には，マンション名に特定のブランド名のキーワードを含む場合は 1，そうでない場合は 0 のフラグ情報として特徴量を作成した．

6. 実験結果及び考察

各種手法を用いた実験結果を表 3 に示す．今回の実験を行うのに際して，比較対象として [福井 18] のニューラルネットワークによる実装も行った．ニューラルネットワークを用いた手法が MAPE10.83%なのに対し，本研究で提案する LightGBM をベースにした各種モデルでは，全てそれを上回る結果となった．

図 1 及び図 2 に，各特徴量のモデルの予測結果に対する SHAP value を示す．SHAP value [Lundberg 17] とは，それぞれの特徴量がその予想にどのような影響を与えたかを算出したもので，赤色は予測値の増加を表し，青色は予測値の減少を表している．

図 1 は，全特徴量のうち，予測結果への寄与度 (Importance) の高い順に上位 20 位までを表示したものである．専有面積や築年，間取り，所在地，駅といった属性情報が予測結果に大きく影響している事がわかる．これは，不動産投資家が目利きを行う際に重視する項目の順番と直感的にも概ね一致している．

図 2 は，各種 Geo Data の特徴量が予測結果への寄与度を示したものである．マンションの緯度・経度の座標値だけでなく，最寄り駅の緯度・経度との差分も予測結果に大きく影響している事がわかる．

7. まとめ

本研究では，不動産投資市場における収益物件の情報収集及び自動分析のサポートシステムの構築を目的とし，それを実現するための高精度価格推定モデルを提案した．LightGBM をベースに，Geo Data 及びマンションブランドといった特徴量

*4 https://www.geocoding.jp/api/

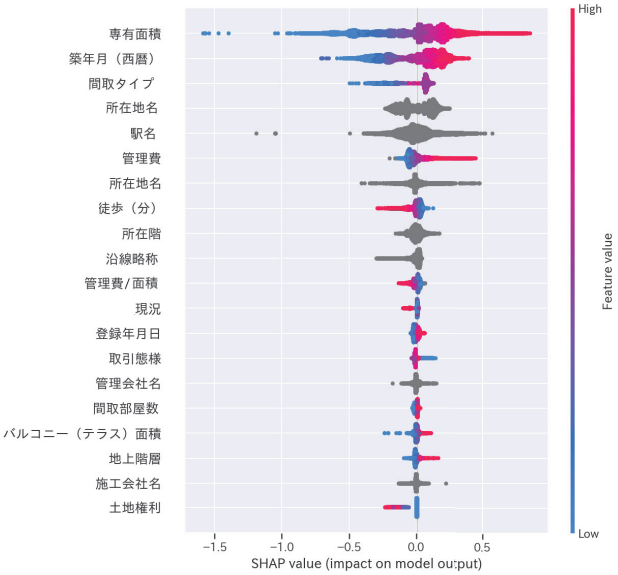


図 1: Importance 上位 20 位の特徴量



図 2: 各種 Geo Data 特徴量の Importance

作成の工夫を施す事で，ニューラルネットワークを用いた従来手法よりも大幅な精度向上を実現できた．また，本論文ではモデルの性能評価をシンプルに，かつ厳密に行うために，2018 年までのデータを学習用に，2019 年のデータ 1 年分を全て評価用データとして分離した．これはすなわち 2019 年の 1 年間における不動産市場の相場変動の情報が欠如した状態での実験である．現実的に実用化する際には，推論データにより近い時期の成約データ (例えば推論時点の一週間前までのデータ) も学習に用いるので，実務では更に高精度な価格推定モデルとしての運用が可能である．

今後は更にこれを活用し，スクレイピング等の自動情報収集技術と組み合わせて，効率的な不動産投資を実現するサポートシステムとして世に出していきたい．

謝辞

本論文を執筆するに当たり，技術的な議論やアドバイスを頂いた東京大学の山崎俊彦氏に感謝します．

参考文献

[清水 08] 清水千弘: 不動産市場の情報不完全性と価格形成要因に関する研究，東京大学，博士論文 (2008)

[清水 17] 清水千弘: 不動産ビッグデータでみる不動産価格の決まり方，日本不動産学会誌，32 巻，1 号，pp.45-51 (2017)

[福井 18] 福井光，坂井一仁，南村忠敬，三尾順一，木下明弘，田司郎:「レインズのニューラルネットワークを用いた不動産価格査定について」，The 32nd Annual Conference of the Japanese Society for Artificial Intelligence (2018)

[大和 17] 大和大祐，野村眞平:「SUUMO でのビッグデータ活用事例」，日本不動産学会誌／第 31 巻第 1 号，pp78-83 (2017)

[服部 19] 服部凌典，岡本一志，柴田淳司: 間取り図を用いた賃料予測モデルに関する一検討，The 33nd Annual Conference of the Japanese Society for Artificial Intelligence (2019)

[Ke 17] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, Tie-Yan Liu: LightGBM: A Highly Efficient Gradient Boosting Decision Tree，In Advances in Neural Information Processing Systems, pp 3149–3157 (2017)

[Zhao 19] Qianqian Zhao, Zhuyifan Ye, Yan Su, Defang Ouyang: Predicting complexation performance between cyclodextrins and guest molecules by integrated machine learning and molecular modeling techniques https://doi.org/10.1016/j.apsb.2019.04.004 (2019)

[Lundberg 17] Scott M. Lundberg, Su-In Lee: A Unified Approach to Interpreting Model Predictions, NIPS 2017 (2017)